

ΕΘΝΙΚΟ ΚΑΙ ΚΑΠΟΔΙΣΤΡΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

Προγράμματα Συμπληρωματικής Εκπαίδευσης

Με τη χρήση καινοτόμων μεθόδων εξ αποστάσεως εκπαίδευσης

2011 - ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ R

© Copyright 2021, Εθνικό και Καποδιστριακό Πανεπιστήμιο Αθηνών, Π. Ε. Πετράκης.

Η έντυπη, ηλεκτρονική και γενικά κατά οποιοδήποτε τρόπο αναπαραγωγή, δημοσίευση ή χρησιμοποίηση όλου ή μέρους του υλικού έργου αυτού, απαγορεύεται χωρίς την έγγραφη έγκριση του κατόχου των πνευματικών δικαιωμάτων του έργου.

Το παρόν έντυπο αποτελεί τμήμα του εκπαιδευτικού υλικού του μαθήματος “**Στατιστική στην R**”. Αποτελεί απαραίτητο συμπλήρωμα του ηλεκτρονικού υλικού που βρίσκεται στην πλατφόρμα και αναπόσπαστο κομμάτι της εκπαιδευτικής διαδικασίας.

Στην τέταρτη διδακτική ενότητα παρουσιάζονται βασικές αρχές ομαδοποίησης/ συσταδοποίησης (clustering) όπως η ιεραρχική ομαδοποίηση (hierarchical clustering) και ο αλγόριθμος K-means. Στη συνέχεια, θα παρουσιαστούν οι βασικές έννοιες του version control, με ειδική έμφαση στο Git και το Github.

Τη συγγραφή του συγκεκριμένου εκπαιδευτικού υλικού πραγματοποίησε ο κ. **Παναγόπουλος Δημ.**, εξωτερικός συνεργάτης του Προγράμματος Συμπληρωματικής εξ Αποστάσεως Εκπαίδευσης του Εθνικού και Καποδιστριακού Πανεπιστημίου Αθηνών.

Π Ε Ρ Ι Ε Χ Ο Μ Ε Ν Α

ΔΙΔΑΚΤΙΚΗ ΕΝΟΤΗΤΑ 4. ΣΥΣΤΑΔΟΠΟΙΗΣΗ (CLUSTERING)	5
ΕΙΣΑΓΩΓΙΚΕΣ ΠΑΡΑΤΗΡΗΣΕΙΣ	7
ΥΠΟΕΝΟΤΗΤΑ 1. ΙΕΡΑΡΧΙΚΗ ΟΜΑΔΟΠΟΙΗΣΗ.....	8
ΥΠΟΕΝΟΤΗΤΑ 2. K-MEANS	12
ΥΠΟΕΝΟΤΗΤΑ 3. VERSION CONTROL.....	15
ΥΠΟΕΝΟΤΗΤΑ 4. ΔΗΜΙΟΥΡΓΙΑ ΑΠΟΘΕΤΗΡΙΟΥ ΣΤΟ GITHUB.....	17
ΣΥΝΟΨΗ	21
 BIBΛΙΟΓΡΑΦΙΑ	 22

ΕΘΝΙΚΟ ΚΑΙ ΚΑΠΟΔΙΣΤΡΙΑΚΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΑΘΗΝΩΝ

Προγράμματα Συμπληρωματικής Εκπαίδευσης

Με τη χρήση καινοτόμων μεθόδων εξ αποστάσεως εκπαίδευσης

2011 - ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ R

ΔΙΔΑΚΤΙΚΗ ΕΝΟΤΗΤΑ 4. ΣΥΣΤΑΔΟΠΟΙΗΣΗ (CLUSTERING)

Εισαγωγικές Παρατηρήσεις

Η παρούσα ενότητα αποτελείται από τέσσερις υποενότητες. Στην πρώτη υποενότητα παρουσιάζεται η τεχνική των ιεραρχικών δένδρων ομαδοποίησης καθώς και κάποια πράγματα σχετικά με την αξιολόγηση των μοντέλων ομαδοποίησης. Στη δεύτερη υποενότητα παρουσιάζεται ο αλγόριθμος (και η αντίστοιχη τεχνική) K-means.

Στην τρίτη υποενότητα γίνεται μια σύντομη εισαγωγή και ιστορική αναδρομή στην έννοια του version control. Στην τέταρτη υποενότητα οι εκπαιδευόμενοι θα δουν στην πράξη τη λειτουργία ενός τέτοιου συστήματος μέσω της πλατφόρμας Github.

ΥΠΟΕΝΟΤΗΤΑ 1. ΙΕΡΑΡΧΙΚΗ ΟΜΑΔΟΠΟΙΗΣΗ

Στην υποενότητα αυτή παρουσιάζεται η ιεραρχική ομαδοποίηση (hierarchical clustering).

1.1 Ιεραρχική Ομαδοποίηση

Οι αλγόριθμοι ιεραρχικής ταξινόμησης χωρίζονται σε δύο κατηγορίες, τους αλγόριθμους συγκόλλησης (agglomerative) και τους αλγόριθμους διαίρεσης (divisive). Στην πρώτη κατηγορία ο αλγόριθμος ξεκινά θεωρώντας ότι κάθε παρατήρηση/στοιχείο του dataset αποτελεί μια διαφορετική ομάδα. Στη συνέχεια, συγχωνεύει τις ομάδες σύμφωνα με κάποιο κριτήριο. Η διαδικασία συνεχίζεται μέχρι να ενοποιηθούν όλες οι παρατηρήσεις σε μια ομάδα. Στους αλγόριθμους διαίρεσης ακολουθείται η αντίθετη πορεία. Δηλαδή, ο αλγόριθμος ξεκινά θεωρώντας ότι υπάρχει μόνο μια ομάδα που περιέχει όλες τις παρατηρήσεις. Στη συνέχεια, σπάει τις ομάδες σε μικρότερες μέχρι να καταλήξει σε ομάδες που να περιέχουν ή μια παρατήρηση ή κάθε μία.

Οι βασικές παράμετροι (άρα και αποφάσεις που καλείται να πάρει ο αναλυτής δεδομένων) είναι:

- Ο τρόπος με τον οποίο θα υπολογίσει την απόσταση μεταξύ των στοιχείων του dataset. Αν κάθε στοιχείο παριστάνεται από ένα διάνυσμα αριθμητικών μεταβλητών, τότε κλασικοί τρόποι υπολογισμού είναι η ευκλείδεια μετρική, η μετρική Manhattan και άλλες. Αν στα δεδομένα μας έχουμε και κατηγορικές μετρικές, τότε οι επιλογές πολλαπλασιάζονται. Σημαντικό είναι να γνωρίζουμε ότι οι κατηγορικές μεταβλητές, ειδικά αυτές με λίγες τιμές (π.χ. φύλο) τείνουν να κυριαρχούν των υπολοίπων. Για παράδειγμα, αν είχαμε μια μεταβλητή με το φύλο ανθρώπων, τότε ένας διαιρετικός αλγόριθμος μπορεί να επέλεγε να σπάσει τον αρχικό cluster σε δύο ανάλογα με το φύλο.
- Το κριτήριο με το οποίο συγχωνεύονται ή σπάνε οι ομάδες σε κάθε βήμα. Μια επιλογή είναι να συνενώσει (ή αντίστοιχα να σπάσει) κάποιος ομάδες που απέχουν τη μικρότερη απόσταση μεταξύ τους. Για να υπολογιστεί η απόσταση μεταξύ δύο ομάδων A και B υπάρχουν πάλι αρκετοί τρόποι. Ως απόσταση μπορεί να θεωρηθεί η μικρότερη απόσταση μεταξύ δύο παρατηρήσεων a,b. Η a από την μια ομάδα A και η b από την ομάδα B. Ή μπορεί να θεωρηθεί η μεγαλύτερη

απόσταση μεταξύ δύο παρατηρήσεων a , b όπως πριν. Ή να χρησιμοποιηθεί η απόσταση των κέντρων τους κ.α.

- Το στάδιο του που θα χρησιμοποιηθεί. Οι αλγόριθμοι ιεραρχικής ομαδοποίησης έχουν δύο ακραίες καταστάσεις: μια μόνο ομάδα με όλα τα δεδομένα και τόσες ομάδες όσες και τα δεδομένα. Ο αναλυτής θα πρέπει να αποφασίσει ποιο από τα ενδιάμεσα στάδια θα χρησιμοποιήσει.

Προσοχή: Επειδή οι διαφορετικές κλίμακες που έχουν οι μεταβλητές μεταξύ τους επηρεάζουν την ανάλυση η συνήθης τακτική είναι να κανονικοποιούνται. Για το τελευταίο, οι πιο διαδεδομένες μέθοδοι είναι:

- η αφαίρεση από όλες τις τιμές του μέσου όρου της μεταβλητής και η διαίρεση του αποτελέσματος με τη τυπική απόκλισή της,
- η αφαίρεση από όλες τις τιμές της ελάχιστης τιμής της μεταβλητής και η διαίρεση του αποτελέσματος με το εύρος (=μέγιστή τιμή – ελάχιστη τιμή) της.

Στο παράδειγμά μας, έχουμε δύο κατηγορικές μεταβλητές που εκφράζονται με αριθμούς (Channel και Region) και συνεχείς/αριθμητικές μεταβλητές. Συνεπώς, μπορούμε να χρησιμοποιήσουμε τη συνήθη ευκλείδεια μετρική. Θα δουλέψουμε με έναν αλγόριθμο συνένωσης και για κριτήριο συνένωσης των ομάδων θα χρησιμοποιήσουμε τη λεγόμενη Ward's method. Η μέθοδος αυτή χρησιμοποιεί τη μεταβολή του αθροίσματος τετραγώνου της απόστασης κάθε σημείου από το κέντρο της ομάδας όπου ανήκει. Ειδικότερα, αν τα σημεία $x_1, \dots, x_m$ ανήκουν στην ομάδα C_1 και τα σημεία $y_1, \dots, y_l$ στην ομάδα C_2 , τότε για να αποφασίσει ο αλγόριθμος αν θα συνενώσει τις C_1 και C_2 υπολογίζει τη διαφορά:

$$\begin{aligned} &|x_1 - m_{1,2}|^2 + \dots + |x_m - m_{1,2}|^2 + |y_1 - m_{1,2}|^2 + \dots + |y_l - m_{1,2}|^2 \\ &\quad - |x_1 - m_1|^2 - \dots - |x_m - m_1|^2 \\ &\quad - |y_1 - m_2|^2 + \dots + |y_l - m_2|^2 \end{aligned}$$

όπου m_1 είναι το κέντρο του C_1 , m_2 είναι το κέντρο του C_2 και $m_{1,2}$ είναι το κέντρο του $C_1 \cup C_2$. Οι ομάδες C_1, C_2 που συνενώνονται είναι αυτές για τις οποίες η παραπάνω διαφορά είναι η μικρότερη δυνατή.

1.2 Εφαρμογή

Θα χρησιμοποιήσουμε ως παράδειγμα το ενσωματωμένο dataset iris της R. Με την εντολή:

```
> ?iris
```

παίρνετε πληροφορίες για το αυτό το σύνολο δεδομένων. Εκεί διαβάζετε ότι αποτελείται από 3 είδη του λουλουδιού Iris. Για την ανάλυσή μας, θα υποθέσουμε ότι δεν γνωρίζουμε που ανήκει το κάθε δείγμα. Τα δεδομένα που θα χρησιμοποιήσουμε θα είναι οι τέσσερις πρώτες στήλες του iris.

```
> dat=iris[,1:4]
```

Ξεκινάμε κανονικοποιώντας τα δεδομένα μας με την εντολή scale. Αυτή η διαδικασία είναι καλό να γίνεται έτσι ώστε οι διαφορετικές κλίμακες να μην διαστρεβλώσουν τα αποτελέσματα.

```
> pmatrix = scale(dat)
```

Ο αλγόριθμος που θα χρησιμοποιήσουμε χρειάζεται ως είσοδο την απόσταση μεταξύ των σημείων του συνόλου δεδομένων. Η τελευταία υπολογίζεται με την εντολή dist.

```
> d = dist(pmatrix)
```


Η δημιουργία του δένδρου γίνεται με την εντολή hclust, στην παράμετρο method έχουμε τη μέθοδο ward που χρησιμοποιούμε.

```
> c = hclust(d, method="ward.D2")
```

Μπορούμε να δούμε το δένδρο με την εντολή:

```
> plot(c)
```


Εικόνα 1. Ιεραρχικό δένδρο ομαδοποίησης για το σύνολο δεδομένων iris



Παρατηρούμε ότι ξεχωρίζουν τρεις μεγάλες ομάδες. Μπορούμε να τις δούμε στο δένδρο με την εντολή:

```
> rect.hclust(c, k=3)
```

Εικόνα 2. Οι τρεις ομάδες στο ιεραρχικό δένδρο ομαδοποίησης για το σύνολο δεδομένων *wholesale customers*



Η εντολή:

```
> groups <- cutree(c, k =3)
```

λέει στην R ότι θέλουμε να κρατήσουμε τρεις ομάδες από το δένδρο. Το αποτέλεσμα της είναι ένα διάνυσμα όπου στην πρώτη του συντεταγμένη βρίσκεται η ομάδα στην οποία ανήκει η πρώτη παρατήρηση, στη δεύτερη η ομάδα όπου ανήκει η δεύτερη παρατήρηση κ.ο.κ.

Μπορούμε να δούμε πώς τα πήγε ο αλγόριθμος σε σχέση με τις πραγματικές ομάδες δημιουργώντας έναν πίνακα διπλής εισόδου:

```
> table(iris$species,groups)
      groups
      1  2  3
setosa 49  1  0
versicolor 0 27 23
virginica 0  2 48
```

Βλέπουμε ότι έχει εντοπίσει πλήρως το είδος *setosa*, ενώ η δεύτερη ομάδα που έχει δημιουργήσει το δένδρο αποτελείται σχεδόν αποκλειστικά από το είδος *versicolor*. Η τρίτη ομάδα αποτελείται κατά τα δύο τρίτα από το είδος *virginica* και κατά το υπόλοιπο ένα τρίτο από το είδος *versicolor*.

ΥΠΟΕΝΟΤΗΤΑ 2. K-MEANS

Στην υποενότητα αυτή παρουσιάζεται η ομαδοποίησης με τη χρήση του αλγόριθμου k-means.

2.1 Περιγραφή του k-means

Ο αλγόριθμος k-means είναι ένας από τους πιο ευρέως χρησιμοποιούμενους αλγόριθμους για την ομαδοποίηση συνόλων δεδομένων. Δέχεται ως είσοδο ένα σύνολο δεδομένων και τον αριθμό k των επιθυμητών ομάδων. επιστρέφει ως έξοδο μια ταξινόμηση των στοιχείων του συνόλου δεδομένων σε k ομάδες ή/και και τα κέντρα αυτών των k ομάδων.

Οι ομάδες αυτές επιλέγονται ώστε το άθροισμα των τετραγώνων των αποστάσεων κάθε σημείου από το κέντρο της αντίστοιχης ομάδας να είναι το μικρότερο δυνατό. Δηλαδή αν $\vec{x}_1, \dots, \vec{x}_n$ είναι τα στοιχεία του συνόλου δεδομένων και $\vec{\mu}_1, \dots, \vec{\mu}_k$ τα κέντρα των αντίστοιχων ομάδων $C_1, \dots, C_k$ ο αλγόριθμος θέλει να ελαχιστοποιήσει την τιμή:

$$T = \sum_{x_i \in C_j} d(\vec{x}_i, \vec{\mu}_j)^2$$

όπου το κέντρο $\vec{\mu}_j$ της ομάδας C_j είναι το βαρύκεντρο των σημείων που ανήκουν στην ομάδα αυτή, δηλαδή:

$$\vec{\mu}_j = \frac{1}{\#C_j} \sum_{x_i \in C_j} \vec{x}_i$$

με $\#C_j$ να είναι το πλήθος των στοιχείων της ομάδας C_j . Τέλος, $d(\vec{z}, \vec{w})$ είναι η απόσταση μεταξύ των σημείων $\vec{z}, \vec{w}$. Συνήθως, χρησιμοποιείται η συνήθης ευκλείδεια απόσταση.

Το πρόβλημα αυτό είναι δύσκολο (τεχνικά είναι NP-complete) και ο αλγόριθμος k-means προσπαθεί να βρει μια προσεγγιστική λύση. Αυτό το κάνει εκτελώντας τα παρακάτω βήματα:


1. επιλέγει στην τύχη k σημεία ως κέντρα των k ομάδων,
2. για κάθε σημείο βρίσκει το πλησιέστερο κέντρο και κατατάσσει το σημείο στην αντίστοιχη ομάδα,
3. επαναυπολογίζει τα βαρύκεντρα των ομάδων,
4. επαναλαμβάνει τα βήματα 2 και 3.

Οι επαναλήψεις συνεχίζονται μέχρι να ικανοποιηθεί μια συνθήκη. Οι συννηθέστερες είναι:

- συγκεκριμένος αριθμός επαναλήψεων ή
- μια μικρή μεταβολή του αθροίσματος των τετραγώνων των αποστάσεων κάθε σημείου από το κέντρο της αντίστοιχης ομάδας ή
- μια μη μεταβολή των κέντρων

Στην εικόνα 3 φαίνεται μια επανάληψη του αλγόριθμου.

Εικόνα 3. Διαδοχικά βήματα του k-means



Πηγή: Wikimedia commons, δημιουργός Weston.pace

2.2 k-means και R

Ο αλγόριθμος k-means υλοποιείται στην R μέσω της εντολής kmeans.

Ένα από τα προβλήματα με τη χρήση του k-means είναι η επιλογή του αριθμού των ομάδων k. Ένας τρόπος για να επιλεγεί είναι να δοκιμάσουμε διάφορες τιμές και στη συνέχεια να διαλέξουμε την καλύτερη με βάση κάποιο κριτήριο. Ένα από αυτά είναι να υπολογίσουμε το άθροισμα των τετραγώνων των αποστάσεων των σημείων από τα αντίστοιχα κέντρα τους:

$$T = \sum_{x_i \in C_j} d(\vec{x}_i, \vec{\mu}_j)^2$$

(η τιμή αυτή αναφέρεται ως total within sum of squares στη βιβλιογραφία.)

Επιλέγουμε ως αριθμό ομάδων την τιμή εκείνη του k από την οποία και μετά δεν υπάρχει μεγάλη μείωση του T. Πρακτικά αυτό γίνεται κάνοντας τη γραφική παράσταση των

τιμών total within sum of squares ανά k . Εκεί, προσπαθούμε να εντοπίσουμε μια γωνία που θα υποδηλώνει το επιθυμητό σημείο.

Ο παρακάτω κώδικας εκτελεί τον k -means για τιμές του k από 2 έως 10 και κρατά το αντίστοιχο total within sum of squares στη μεταβλητή `totwinss` (θυμηθείτε ότι δεν πληκτρολογούμε τα "+"):


```
> totwinss=c()  
> for (k in 2:10){  
+   k_cl=kmeans(pmatrix,k)  
+   totwinss[k] <- k_cl$tot.withinss  
+ }
```

Οι εντολές:

```
> plot(1:10, totwinss,  
+      xlab = "Number of clusters",  
+      ylab = "Total within ss")  
> lines(1:10, totwinss)
```

δημιουργούν το γράφημα των τιμών total within sum of squares ανά k .

Εικόνα 4. Διάγραμμα total within sum of squares ανά k



Βλέπουμε ότι για την τιμή $k=3$ έχουμε μια γωνία. Εκτελούμε ξανά τον k -means για $k=3$.

```
> k_cl=kmeans(pmatrix,3)
```

Και πάλι, μπορούμε να δούμε πώς τα πήγε ο αλγόριθμος σε σχέση με τις πραγματικές ομάδες δημιουργώντας έναν πίνακα διπλής εισόδου.

```
> table(iris$species,k_cl$cluster)
```

	1	2	3
setosa	0	0	50
versicolor	39	11	0
virginica	14	36	0

Βλέπουμε ότι και πάλι η μια ομάδα που έχει δημιουργηθεί αποτελείται αποκλειστικά από το είδος *setosa*. Οι άλλες δύο αποτελούνται η μια κατά τα δύο τρίτα από το είδος *versicolor* και κατά ένα τρίτο από το είδος *virginica* και αντίστροφα η άλλη.

ΥΠΟΕΝΟΤΗΤΑ 3. VERSION CONTROL

Σύμφωνα με τη Wikipedia, ως version control ορίζονται συστήματα που είναι υπεύθυνα για τη διαχείριση αλλαγών σε αρχεία κώδικα, κειμένου, εικόνας κ.α. Στη σημερινή εποχή τέτοια συστήματα είναι πολύ διαδεδομένα. Ο λόγος είναι ότι πλέον η ανάπτυξη λογισμικού γίνεται από πολυπληθείς ομάδες. Είναι συνεπώς επιτακτική η ανάγκη συστημάτων version control.

Τα συστήματα αυτά επιτρέπουν σε ομάδες προγραμματιστών (αλλά και αναλυτών δεδομένων, *data scientists* κ.α.) να δουλεύουν στην ανάπτυξη ενός προϊόντος κρατώντας ένα λεπτομερές ιστορικό των αλλαγών, διατηρώντας αντίγραφα περασμένων εκδόσεων, επιτρέποντας σε όλα τα μέλη της ομάδας να ενημερώνονται και να έχουν πρόσβαση στην πιο πρόσφατη έκδοση.

Μεταξύ αυτών των συστημάτων, ιδιαίτερη μνεία αξίζει στο Github. Είναι μια πλατφόρμα που παρέχει τέτοιες υπηρεσίες μέσω διαδικτύου. Αυτό που την κάνει να ξεχωρίζει είναι το μεγάλο πλήθος χρηστών που έχει καθώς και το γεγονός ότι πολλά έργα της κοινότητας ανοικτού λογισμικού τη χρησιμοποιούν. Είναι δε ένα πολύ δημοφιλές μέρος όπου διάφοροι επαγγελματίες μπορούν να προβάλλουν το χαρτοφυλάκιο έργων τους (*portfolio*). Μπορεί με αυτόν τον τρόπο να λειτουργήσει ως ένα χρήσιμο εργαλείο στην αναζήτηση μιας θέσης εργασίας.

3.1 Ιστορία

Η πιο απλή μορφή version control είναι η διατήρηση διαφορετικών εκδόσεων (αρχείων) τοπικά. Αυτό συνήθως συνδυάζεται με την προσθήκη μιας ένδειξης ημερομηνίας π.χ. *Book_Jan*, *Book_Feb*, *Book_Mar*. Το επόμενο, πιο σύνθετο στάδιο είναι η χρήση εξειδικευμένου λογισμικού που συντηρεί μια βάση δεδομένων με πληροφορίες για τις διάφορες εκδόσεις των αρχείων.

Τέτοια εξειδικευμένα λογισμικά υπάρχουν ήδη από τη δεκαετία του 1960. Το πρώτο ολοκληρωμένο σύστημα θεωρείται το SCCS, που δημιουργήθηκε το 1972 από τον Marc Rochkind στα εργαστήρια Bell. Τα πρώτα αυτά λογισμικά ακολουθούν την αρχιτεκτονική «πελάτη-εξυπηρετητή» ("client-server"). Σε αυτή ένας κεντρικός εξυπηρετητής έχει την πιο πρόσφατη έκδοση ενός αρχείου. Ο πελάτης συνδέεται με τον εξυπηρετητή για να πάρει (ή ενημερώσει) την πιο πρόσφατη έκδοση. Ο εξυπηρετητής έχει την ευθύνη του συντονισμού απορρίπτοντας αλλαγές που αφορούν παλαιότερες εκδόσεις ενός αρχείου. Ειδικότερα, οι πελάτες μπορούν να κάνουν αλλαγές μόνο στην πιο πρόσφατη έκδοση ενός αρχείου. Ολόκληρη η δομή δεδομένων που περιλαμβάνει τις διαφορετικές εκδόσεις των αρχείων και το ιστορικό αλλαγών τους ονομάζεται αποθετήριο (repository).

Το πιο διαδεδομένο τέτοιο λογισμικό είναι το Apache Subversion. Το Apache Subversion δημιουργήθηκε από την εταιρεία CollabNet VersionOne το 2000. Είναι ένα εργαλείο ανοικτού κώδικα και είναι ένα από τα κεντρικά πρότζεκτ του Apache.

Ένα από τα μειονεκτήματα της παραπάνω αρχιτεκτονικής είναι ότι ο εξυπηρετητής είναι ζωτικής σημασίας για τη λειτουργία του συστήματος. Μια βλάβη στον εξυπηρετητή θα θέσει εκτός λειτουργίας όλο το σύστημα, ενώ και η πιο πρόσφατη έκδοση των αρχείων αλλά και ολόκληρο το ιστορικό αλλαγών είναι αποθηκευμένα σε αυτόν με ό,τι αυτό συνεπάγεται στην περίπτωση καταστροφής του.

Τους κινδύνους αυτούς έρχονται να αντιμετωπίσουν τα αποκεντρωμένα συστήματα (Distributed Version Control Systems – DVCSs). Σε αυτά τα συστήματα οι πελάτες έχουν ένα πλήρες αντίγραφο και της πιο πρόσφατης έκδοσης των αρχείων αλλά και του ιστορικού των αλλαγών τους. Έτσι, σε περίπτωση απώλειας του εξυπηρετητή όλες οι απαραίτητες πληροφορίες για την αποκατάσταση του συστήματος είναι διαθέσιμες στους πελάτες.

Το πιο διαδεδομένο σύστημα Distributed Version Control είναι το Git. Το Git δημιουργήθηκε το 2005 από τον Linus Torvalds, δημιουργό του Linux για να βοηθήσει στην ανάπτυξη του λειτουργικού αυτού συστήματος.

3.2 Github

Το Github είναι μια εταιρεία που παρέχει υπηρεσίες version control μέσω διαδικτύου. Βασίζεται στο Git και παρέχει αρκετές από τις υπηρεσίες του δωρεάν. Έχει πάνω από 65 εκατομμύρια χρήστες και περισσότερα από 200 εκατομμύρια αποθετήρια. Ένα μεγάλο πλήθος εταιρειών χρησιμοποιούν το Github. Ανάμεσά τους είναι οι Airbnb, Netflix,

Udemy, Reddit. Ανάμεσα σε αυτές είναι και η Microsoft. Μάλιστα, στις 26 Οκτωβρίου 2018 η Microsoft εξαγόρασε το Github έναντι του ποσού των 7,5 δισεκατομμυρίων δολαρίων.

Ανάμεσα στα άλλα πλεονεκτήματα που προσφέρει το Github είναι και η δυνατότητα να εκτελεί κάποιος βασικές λειτουργίες διαχείρισης αποθετηρίων μέσω web browser. Στην επόμενη ενότητα θα δημιουργήσουμε ένα αποθετήριο στο Github.


ΥΠΟΕΝΟΤΗΤΑ 4. ΔΗΜΙΟΥΡΓΙΑ ΑΠΟΘΕΤΗΡΙΟΥ ΣΤΟ GITHUB

Στην υποενότητα αυτή θα δούμε τα βήματα δημιουργίας ενός αποθετηρίου στο Github.

4.1 Εγγραφή στο Github

Το πρώτο βήμα για την χρήση του Github είναι η εγγραφή σε αυτό. Η διαδικασία απαιτεί τη χρήση ενός λογαριασμού ηλεκτρονικού ταχυδρομείου αλλά κατά τα άλλα είναι πολύ απλή. Για να γραφτεί κάποιος αρκεί να μεταβεί στην ιστοσελίδα που βλέπετε στο αντίστοιχο σημείο του ηλεκτρονικού υλικού. Εκεί πατάτε στο εικονίδιο που γράφει “Sign up” (Εικόνα 5).

Εικόνα 5. Η αρχική σελίδα του Github όπως είναι σήμερα (Ιούλιος 2021)



Το Github θα ζητήσει ένα όνομα χρήστη, ένα password και μια διεύθυνση email. Στη διεύθυνση αυτή θα αποσταλεί ένα μήνυμα (αν δεν το εντοπίσετε, κοιτάξτε μήπως έχει βρεθεί στην ανεπιθύμητη αλληλογραφία). Μόλις πατήσετε το σύνδεσμο στο email, θα


έχετε επιβεβαιώσει την διεύθυνση ηλεκτρονικού ταχυδρομείου και θα έχετε ολοκληρώσει την εγγραφή σας. Υπάρχει το ενδεχόμενο το Github να σας κάνει κάποιες ερωτήσεις σχετικά με το είδος της χρήσης που θα κάνετε. Είστε ελεύθεροι να επιλέξετε ότι σας ταιριάζει καλύτερα. Σε περίπτωση που ερωτηθείτε για αν θέλετε να γραφτείτε συνδρομητές έναντι κάποιου ποσού ή όχι, **επιλέξτε το δωρεάν πλάνο**.

Δυστυχώς λόγω συχνών αλλαγών στη διαδικασία, δεν είναι δυνατή η πιο αναλυτική παρουσίαση της διαδικασίας. Παρ' όλα αυτά, στους «χρήσιμους συνδέσμους στο διαδίκτυο» υπάρχει ένα link με ένα video που περιγράφει τη διαδικασία.

4.2 Δημιουργία αποθετηρίου

Αφού έχετε ολοκληρώσει την εγγραφή σας, είστε έτοιμοι να δημιουργήσετε το πρώτο σας αποθετήριο. Αυτό γίνεται πατώντας στο κουμπί "Create repository" (ή "New" βλ. Εικόνα 6). Θα σας ζητηθεί να δώσετε κάποιο όνομα για το αποθετήριο. Αν θέλετε μπορείτε να δώσετε μια περιγραφή. Μπορείτε επίσης να επιλέξετε αν το αποθετήριο θα είναι δημόσιο ή ιδιωτικό. Επειδή στις ασκήσεις θα σας ζητηθεί να στείλετε κάτι σχετικά με αποθετήρια του Github, καλό είναι επιλέξετε το αποθετήριο να είναι δημόσιο.

Εικόνα 6. Δημιουργία του πρώτου σας αποθετηρίου



Τέλος, μαρκάρετε την επιλογή “Add a README file” και πατήστε το κουμπί “Create repository” (βλ. Εικόνα 7). Συγχαρητήρια! Μόλις δημιουργήσατε το πρώτο σας αποθετήριο.

Εικόνα 7. Προσθήκη αρχείου README και δημιουργία αποθετηρίου



Initialize this repository with:

Skip this step if you're importing an existing repository.

☐ Add a README file
This is where you can write a long description for your project. [Learn more.](#)

☐ Add .gitignore
Choose which files not to track from a list of templates. [Learn more.](#)

☐ Choose a license
A license tells others what they can and can't do with your code. [Learn more.](#)


[Create repository](#)

Το Github θα έχει δημιουργήσει ένα αποθετήριο με ένα αρχείο README.md Τα αρχεία αυτά έχουν πληροφορίες σχετικά με το κάθε αποθετήριο και εμφανίζονται αυτόματα στην κεντρική σελίδα του αποθετηρίου. Είναι γραμμένα με ειδική σύνταξη που ονομάζεται Markdown. Ένα αποθετήριο μπορεί να περιέχει και άλλα αρχεία γραμμένα με Markdown. Συνήθως αυτά έχουν την κατάληξη “.md”. Άσχετα με το πλήθος τους, το αρχείο README.md είναι αυτό που εμφανίζεται αυτόματα στην κεντρική σελίδα του αποθετηρίου.

4.3 Ενημέρωση αρχείου README

Ως τελικό βήμα, θα κάνουμε μια αλλαγή στο αρχείο README.md. Αυτό γίνεται πατώντας το σχετικό κουμπί που απεικονίζει ένα μολύβι (βλ. Εικόνα 8).

Εικόνα 8. Κουμπί για την αλλαγή του αρχείου README.md




Θα δείτε ότι θα ανοίξει ένα νέο παράθυρο όπου μπορείτε να επεξεργαστείτε τα περιεχόμενα του αρχείου README.md Μπορείτε να κάνετε τις τροποποιήσεις που επιθυμείτε. Κάποια λίγα πράγματα σχετικά με τα Markdown αρχεία:

- γραμμές που ξεκινούν με ένα σύμβολο δέσης # θα εμφανιστούν με μεγάλη, έντονη γραμματοσειρά, όπως π.χ. ένας τίτλος,
- γραμμές που ξεκινούν με δύο σύμβολα δέσης ## θα εμφανιστούν με την αμέσως μεγαλύτερη, έντονη γραμματοσειρά, όπως π.χ. ένας υπότιτλος. Αντίστοιχα και για γραμμές που ξεκινούν με τρία σύμβολα δέσης ### ,
- κείμενο που είναι μεταξύ * (αστερίσκου) θα είναι σε italics,
- κείμενο που είναι μεταξύ δύο * (αστερίσκων) θα είναι έντονο (bold),
- μπορείτε να φτιάξετε bullet list ξεκινώντας τις αντίστοιχες γραμμές με * (αστερίσκο),
- οι σύνδεσμοι (links) σε ιστοσελίδες εισάγονται τοποθετώντας το κείμενο του συνδέσμου σε παρενθέσεις και στη συνέχεια τη διεύθυνση του συνδέσμου σε αγκύλες,
- εικόνες μπορούν να προστεθούν βάζοντας το θαυμαστικό ακολουθούμενο από τον τίτλο της εικόνας μέσα σε αγκύλες και στη συνέχεια το σύνδεσμο για την εικόνα μέσα σε παρενθέσεις.

Στον σύνδεσμο που βρίσκεται στο αντίστοιχο σημείο του ηλεκτρονικού υλικού μπορείτε να διαβάσετε περισσότερες λεπτομέρειες σχετικά με τη σύνταξη Markdown κειμένου. Ενώ μπορείτε να δείτε και ένα μικρό παράδειγμα στο αποθετήριο του συγγραφέα.

Αφού ολοκληρώσετε τις αλλαγές, μπορείτε να ενημερώσετε το αποθετήριο πατώντας στο κουμπί "Commit changes". Καλό είναι κάθε φορά που κάνετε αλλαγές στο αποθετήριο να γράφετε μια σύντομη περιγραφή των αλλαγών που κάνατε.

Εικόνα 9. Ενημέρωση του αποθετηρίου με τις αλλαγές



Σύνοψη

Με την ολοκλήρωσή αυτής της ενότητας μάθατε:

- την τεχνική της ιεραρχικής ομαδοποίησης (hierarchical clustering),
- να εφαρμόζετε την τεχνική της ιεραρχικής ομαδοποίησης (hierarchical clustering) στην R,
- την τεχνική K-means,
- να εφαρμόζετε την τεχνική K-means στην R,
- για το version control,
- για το Github,
- για τη σύνταξη Markdown, και
- να δημιουργείτε το πρώτο σας αποθετήριο.

ΒΙΒΛΙΟΓΡΑΦΙΑ

- **Δ. Καρλής, Ι. Ντζούφρας**, *Εισαγωγή στον προγραμματισμό και στη Στατιστική ανάλυση με R*, Τμήμα Στατιστικής Ο.Π.Α., 2015, kallipos.gr
- **Abreu, N.** (2011). *Análise do perfil do cliente Recheio e desenvolvimento de um sistema promocional*. Mestrado em Marketing, ISCTE-IUL, Lisbon
- **Cortez, P.**, *Modern Optimization with R*, Springer, 2014.
- **Davenport T.H. and Patil D.J.**, (2012), "Data Scientist: The Sexiest Job of the 21st Century", *Harvard Business Review*, October 2012, διαθέσιμο στη σελίδα: hbr.org
- **Leland W.**, (2005), *The Grammar of Graphics*, Springer, New York.
- **P. Cortez, A. Cerdeira, F. Almeida, T. Matos and J. Reis**. *Modeling wine preferences by data mining from physicochemical properties*. In *Decision Support Systems*, Elsevier, 47(4):547-553, 2009.